

文献阅读笔记			
题目	Globally-Optimal Contrast Maximisation for Event Cameras（事件摄像机的全局最佳对比度最大化）		
作者	Xin Peng	文献来源	2022 CVPR
研究价值	<p>目前挑战：目前的应用都是局部对比度最大化；现有方法大多依赖于一般非凸对比度最大化目标的局部优化；这个问题是一个非凸优化问题，因为它包含了平方项，这会导致目标函数具有多个局部最优解。</p> <p>我的理解：非凸问题通常需要不同的初始值，以增加找到全局最小值的概率，但它通常需要根据具体问题和算法来进行调整和优化，容易造成局部最优解。</p> <p>本文价值： 核心贡献包括针对这些一般非凸问题导出全局最优解决方案，从而消除了对困扰现有方法的良好初始猜测的依赖。</p>		
研究问题	针对非凸优化问题，提出导出全局最优解的方法，并将这种策略应用于三个常见的计算机视觉问题：光流估计、计算机旋转估计、向下事件相机的运动估计（估计相机本身的姿态）。		
想法动机	<p>我们提出了一种基于分支定界（BnB）优化范式（ϵ 最优解）的高效、全局最优对比度最大化框架（GOCMF）；通过递归方法有效计算给定分支上对比度最大化函数最大值的上限和下限。我们推导出六种不同对比度评估函数的界限。</p> <p>补充定义：</p> <p>① 基于分支定界（简称 BnB）是一种组合优化问题的解决方法，它用于在搜索问题的解空间时，通过不断地分割问题并剪除不可能产生更优解的分支，从而找到问题的最优解或近似最优解。</p> <p>② ϵ 最优解指的是在优化问题中，找到的解在目标函数值上和全局最优解之间的差距小于或等于 ϵ（一个小正数）。</p>		
具体方法			
<p>背景介绍： 根据下式扭曲事件 $e_k \rightarrow e'_k$：</p> $x'_k = W(x_k, t_k; \theta) = x_k - (t_k - t_{ref})\theta$ <p>IWE 是通过累积每个离散像素位置的扭曲事件来生成的：</p> $I(p_{ij} - x'_k) = \sum_{k=1}^N 1(p_{ij} - x'_k) = \sum_{k=1}^N 1(p_{ij} - W(x_k, t_k; \theta))$ <p>其中 $1(\bullet)$ 是指示函数，如果 $(p_{ij} - x'_k)$ 的绝对值小于每个坐标中的阈值，则计为 1，否则计为 0。p_{ij} 是 IWE 中坐标为 $[i, j]^T$ 的像素，称其为累加器位置。设置阈值为 0.5。</p>			

分支定界全局最大化对比度 GOCMF:

1、目标函数:

本文使用了 6 个目标函数: SoS, Var, SoE, SoSA, SoEaS, SoSAaS

具体以 SoS 方差为例:

下面, 我们假设 $L_N = L_{SoS}$ 。给定时间间隔 $[t_{ref}, t_{ref} + \Delta T]$ 内所有 N 个事件的最大目标函数值由下式给出:

$$\max_{\theta \in \Theta} L_N = \max_{\theta \in \Theta} \sum_{p_{ij} \in P} \left[\sum_{k=1}^N 1(p_{ij} - W(x_k, t_k; \theta)) \right]^2$$

其中 Θ 是我们想要最大化目标的搜索空间 (即分支或子分支)。我们的离散问题可以描述为寻找最佳参数, 将 N 个事件分配给网格模式, 以使每个单元格值的平方和最大化。

2、上下界:

(1) 下界

我们通过逐一处理事件来递归计算边界, 每次更新 IWE。这些事件特别是按照时间戳递增的时间顺序进行处理。

对于下界, 可以通过评估搜索空间区间 Θ 上任意点的对比函数来轻松给出, 该区间通常被选为区间中心 θ_0

定理 1: 对于以 θ_0 为中心的搜索空间 Θ , 基于 SoS 的对比度最大化的下界可以由下式给出:

$$\underline{L}_N = \underline{L}_{N-1} + 1 + 2 I^{N-1}(\eta_N^{\theta_0}; \theta_0)$$

其中 $I^{N-1}(p_{ij}; \theta_0)$ 是增量构建的 IWE, 其指数 $N-1$ (其中 $N \geq 1$) 表示已考虑的事件数, 其中

$$\eta_N^{\theta_0} = \text{round}(W(x_N, t_N; \theta_0))$$

返回最接近第 N 个事件的扭曲位置的累加器。

注意, IWE 是通过递增最接近 $\eta_N^{\theta_0}$ 的累加器来迭代更新的。


$$\begin{aligned} \text{证: } 1(p_{ij}; \theta) &= \sum_{k=1}^N 1(p_{ij} - x_k) = \sum_{k=1}^N 1(p_{ij} - W(x_k, t_k; \theta)) \quad \textcircled{1} \\ L_N &= \sum_{p_{ij} \in P} \left[\sum_{k=1}^N 1(p_{ij} - W(x_k, t_k; \theta)) \right]^2 \quad \textcircled{2} \\ &= \sum_{p_{ij} \in P} [I^N(p_{ij}; \theta)]^2 \\ \text{证: } \underline{L}_N &= \sum_{p_{ij} \in P} \left[\sum_{k=1}^N 1(p_{ij} - W(x_k, t_k; \theta_0)) \right]^2 \\ &= \sum_{p_{ij} \in P} [I^{N-1}(p_{ij}; \theta_0) + 1(p_{ij} - W(x_N, t_N; \theta_0))]^2 \\ &= \sum_{p_{ij} \in P} [I^{N-1}(p_{ij}; \theta_0)]^2 + 2 \sum_{p_{ij} \in P} [1(p_{ij} - W(x_N, t_N; \theta_0))] I^{N-1}(p_{ij}; \theta_0) + \sum_{p_{ij} \in P} [1(p_{ij} - W(x_N, t_N; \theta_0))]^2 \\ &= \underline{L}_{N-1} + 2 I^{N-1}(\eta_N^{\theta_0}; \theta_0) + 1 \end{aligned}$$

|p_{ij} - x_N| < 0.5, 则输出为 1
且该事件个扭曲位置递增 1 个累加器

(2) 上界

让我们将 P_k^\ominus 定义为未扭曲事件的所有可能位置 W 周围的边界框。

引理 1：给定一个搜索空间 $\theta \in \Theta$ ，足够小的时间间隔，如果 $W(x_i, t_i; \theta) = W(x_j, t_j; \theta), t_i \leq t_j, 0 < i < j \leq N$ ，则 $P_i^\ominus \subseteq P_j^\ominus$




定理 2：基于 SoS 的对比度最大化的目标函数上限满足：

$$\overline{L}_N = \overline{L}_{N-1} + 1 + 2Q^{N-1} \geq \underline{L}_N$$

其中 $Q^{N-1} = \max_{p_{ij} \in P_N^\ominus} \overline{I}^{N-1}(p_{ij}) \geq I^{N-1}(\eta_N^{\hat{\theta}}; \hat{\theta})$ ， P_N^\ominus 是第 N 个事件的边框， $\hat{\theta}$ 是在区间上最大化 L_N 的最

优参数集， $I^{N-1}(p_{ij})$ 是上界 IWE 中 p_{ij} 的值，我们总是递增边界框中最大累加器。

增量构造如图所示，容易看出上界大于最优结果



下图为 6 种目标函数上下界表示，其中初始界限的选择需要根据目标函数来变化。

Recursive Upper and Lower Bounds for Six Focus Loss Functions

	Upper Bound \overline{L}_N	Lower Bound \underline{L}_N	L_0
SoS	$\overline{L}_{N-1} + 1 + 2Q$	$\underline{L}_{N-1} + 1 + 2I^{N-1}(\eta_N^{\theta_0}; \theta_0)$	0
Var	$\overline{L}_{N-1} + \frac{1}{N_p} - \frac{2w_1}{N_p} + \frac{2}{N_p}Q$	$\underline{L}_{N-1} + \frac{1}{N_p} - \frac{2w_1}{N_p} + \frac{2}{N_p}I^{N-1}(\eta_N^{\theta_0}; \theta_0)$	μ_f^2
SoE	$\overline{L}_{N-1} + (e-1)e^Q$	$\underline{L}_{N-1} + (e-1)e^{I^{N-1}(\eta_N^{\theta_0}; \theta_0)}$	N_p
SoSA	$\overline{L}_{N-1} + (e^\delta - 1)e^{-\delta Q}$	$\underline{L}_{N-1} + (e^\delta - 1)e^{-\delta I^{N-1}(\eta_N^{\theta_0}; \theta_0)}$	N_p
SoEaS	$\overline{L}_{N-1} + w_1(e-1)e^Q + w_2 + 2w_2Q$	$\underline{L}_{N-1} + w_1(e-1)e^{I^{N-1}(\eta_N^{\theta_0}; \theta_0)} + w_2 + 2w_2I^{N-1}(\eta_N^{\theta_0}; \theta_0)$	w_1N_p
SoSAaS	$\overline{L}_{N-1} + w_1(e^\delta - 1)e^{-\delta Q} + w_2 + 2w_2Q$	$\underline{L}_{N-1} + w_1(e^\delta - 1)e^{-\delta I^{N-1}(\eta_N^{\theta_0}; \theta_0)} + w_2 + 2w_2I^{N-1}(\eta_N^{\theta_0}; \theta_0)$	w_1N_p

3、算法：

算法 1 和 2 概述了我们完整的全局最优对比度最大化框架（GOCMF）。我们提出了一种计算上有限的嵌套策略，其中外层 RB 评估目标函数，而内层 BB 估计边界框 P_N^Θ

Algorithm 1. GOCMF: Globally Optimal Contrast Maximisation Framework

Input: event set \mathcal{E} , initial search space Θ , termination threshold τ

Output: optimal warping parameters $\hat{\theta}$

```

1: Initialise  $\theta_0$  with the center of  $\Theta$ 
2:  $\hat{\theta} \leftarrow \theta_0$ 
3: Initialise priority queue  $Q$ 
4:  $\{\bar{L}, \underline{L}\} \leftarrow \text{RB}(\mathcal{E}, \Theta)$ ,  $\bar{L} \leftarrow \underline{L}$ 
5: Push  $\Theta$  into  $Q$  with priority  $\bar{L}$ 
6: while  $Q$  is not empty do
7:   Pop  $\Theta$  from  $Q$ 
8:   if  $\bar{L} - \underline{L} \leq \tau$ , then terminate
9:    $\theta_0 \leftarrow \text{Center of } \Theta$ 
10:  if  $\underline{L} \geq \bar{L}$ , then  $\hat{\theta} \leftarrow \theta_0$ ,  $\bar{L} \leftarrow \underline{L}$ 
11:  Subdivide  $\Theta$  into subspaces  $\Theta_j$ 
12:  for all subspaces  $\Theta_j$  do
13:     $\{\bar{L}_j, \underline{L}_j\} = \text{RB}(\mathcal{E}, \Theta_j)$ 
14:    if  $\bar{L}_j \geq \bar{L}$  then Insert  $\Theta_j$  into  $Q$  with priority  $\bar{L}_j$ 
15: return  $\hat{\theta}$ 

```

Algorithm 2. RB: Recursive Bounds Calculation

Input: event set \mathcal{E} , search space Θ

Output: lower bound \underline{L} , upper bound \bar{L}

```

1: Initialise accumulator image matrices  $\bar{I}$  and  $\underline{I}$  with zeros
2: Initialise  $\underline{L}$ ,  $\bar{L}$  according to Table 1
3:  $\theta_0 \leftarrow \text{center of } \Theta$ 
4: for each event  $e_k \in \mathcal{E}$  do
5:    $\mathcal{P}_k^\Theta \leftarrow \text{BB}(W(\cdot), \Theta, e_k)$ 
6:    $Q = \max_{\mathbf{p}_{ij} \in \mathcal{P}_k^\Theta} \bar{I}(\mathbf{p}_{ij})$ 
7:    $\eta_k^{\theta_0} = \text{round}(W(\mathbf{x}_k, t_k; \theta_0))$ 
8:    $\mathbf{v}_k = \text{argmax}_{\mathbf{p}_{ij} \in \mathcal{P}_k^\Theta} \bar{I}(\mathbf{p}_{ij})$ 
9:   Update  $\underline{L}$ ,  $\bar{L}$  (cf. Table 1)
10:   $\bar{I}(\mathbf{v}_k) = \bar{I}(\mathbf{v}_k) + 1$ 
11:   $\underline{I}(\eta_k^{\theta_0}) = \underline{I}(\eta_k^{\theta_0}) + 1$ 
12: return  $\underline{L}$ ,  $\bar{L}$ 

```

4、在计算机视觉中的应用：

(1) 光流估计

IWE:

$$W(x_k, t_k; \mathbf{v}) = \mathbf{x}_k' = x_k + \mathbf{v}t_k$$

其中 $\mathbf{v} = [v^x, v^y]^T$ ，给定搜索空间的分支为 $V = [v_{\min}^x, v_{\max}^x] \times [v_{\min}^y, v_{\max}^y]$

则边界框为：

$$\underline{x}_k' = x_k + v_{\min}^x t_k, \underline{y}_k' = y_k + v_{\min}^y t_k$$

$$\overline{x}_k' = x_k + v_{\max}^x t_k, \overline{y}_k' = y_k + v_{\max}^y t_k$$

然后我们可以将导出的边界框应用于 GOCMF 来探索全局最优光流。

(2) 使用向下事件相机的视觉里程计

我们依靠最近发布的全局最优 BnB 求解器，使用普通的朝下相机进行无对应 AGV 运动估计。我们采用二维阿克曼转向模型描述 AGV 的常见非完整运动。采用这种 2-DoF 模型可以给 BnB 带来好处，其复杂性很大程度上取决于解空间的维度。连续帧之间的运动可以通过两个参数方便

地描述：相对旋转角 ϕ 的半角和两个视图之间的基线 ρ 。然而，事件的对齐需要相对位姿的时间

参数化，我们在模型中采用角速度 $\omega = \frac{\theta}{t} = \frac{2\phi}{t}$ 和平移速度 $v = \omega r = w\rho \frac{1}{2\sin(\phi)}$ 。因此，从车辆


坐标系 v' 回到 v 的相对变换由下式给出

$$\mathbf{R}_v(t) = \begin{bmatrix} \cos(\omega t) & -\sin(\omega t) & 0 \\ \sin(\omega t) & \cos(\omega t) & 0 \\ 0 & 0 & 1 \end{bmatrix},$$

$$\mathbf{t}_v(t) = \frac{v}{\omega} \begin{bmatrix} 1 - \cos(\omega t) \\ \sin(\omega t) \\ 0 \end{bmatrix}.$$

沿向前方向可能存在位移，我们用符号变量 ℓ 表示；即 $R_v^c = I_{3 \times 3}, t_v^c = [0, \ell, 0]^T$ ；如下图，从相机位

姿 c' （在任意未来时间戳）到 c （在初始时间戳 t_{ref} ）的变换由下式给出



$$\mathbf{R}_c(t) = \mathbf{R}_v^{c^T} \mathbf{R}_v(t) \mathbf{R}_v^c,$$

$$\mathbf{t}_c(t) = -\mathbf{R}_v^{c^T} \mathbf{t}_v^c + \mathbf{R}_v^{c^T} \mathbf{t}_v(t) + \mathbf{R}_v^{c^T} \mathbf{R}_v(t) \mathbf{t}_v^c.$$

使用已知的平面法向量 $n = [0, 0, -1]^T$ 和平面深度 d ，允许将事件 $e_k = \{x_k, t_k, s_k\}$ 转移到 t_{ref} 处的参考

视图中的图像扭曲函数 $W(x_k, t_k; [\omega, v]^T)$ 最终由平面单应方程给出

$$\mathbf{H}(t_k - t_{ref}) \begin{bmatrix} \mathbf{x}_k \\ 1 \end{bmatrix} = \mathbf{K} \left(\mathbf{R}_c(t_k - t_{ref}) - \frac{\mathbf{t}_c(t_k - t_{ref}) \mathbf{n}^T}{d} \right) \mathbf{K}^{-1} \begin{bmatrix} \mathbf{x}_k \\ 1 \end{bmatrix}$$

请注意，此处的 \mathbf{K} 表示具有均匀焦距 f 、零偏斜且主点位于 $[u_0, v_0]^T$ 的常规透视相机校准矩阵；

结果去均匀化后，得：

$$\begin{aligned}\mathbf{x}'_k &= W(\mathbf{x}_k, t_k; [\omega \ v])^\top = [x'_k \ y'_k]^\top, \text{ where} \\ x'_k &= -[y_k - v_0 + l \cdot \frac{f}{d}] \sin(\omega(t_k - t_{\text{ref}})) \\ &\quad + [x_k - u_0 - \frac{f}{d} \cdot \frac{v}{w}] \cos(\omega(t_k - t_{\text{ref}})) + \frac{f}{d} \cdot \frac{v}{w} + u_0, \\ y'_k &= [x_k - u_0 - \frac{f}{d} \cdot \frac{v}{w}] \sin(\omega(t_k - t_{\text{ref}})) \\ &\quad + [y_k - v_0 + l \cdot \frac{f}{d}] \cos(\omega(t_k - t_{\text{ref}})) - l \cdot \frac{f}{d} + v_0.\end{aligned}$$

最后，将 x'_k 和 y'_k 的值限制在区间 $\omega \in W = [\omega_{\min}, \omega_{\max}]$ 和 $v \in V = [v_{\min}, v_{\max}]$ 上来找到边界框 P_k^\ominus ；

(3) 旋转运动估计

我们假设恒定的角速度 w 来参数化足够小的时间间隔内的旋转运动，旋转由下式表示：

$$\mathbf{R}(t; \omega) = \exp(\omega^\wedge t),$$

其中 w^\wedge 是 w 的 3×3 螺旋对称矩阵形式，IWE 函数：


$$\mathbf{f}'_k = \exp(\omega^\wedge t_k) \mathbf{f}_k,$$

其中， $\mathbf{f}_k = \text{normalize}(K^{-1}[x_k^T, 1]^T)$ 是事件 x_k 在时间 t_k 处的方位向量， \mathbf{f}'_k 是在时间 t_{ref} 处以参考系表示的旋转方位向量。因此，我们将 \mathbf{f}'_k 投影到图像平面以获得扭曲事件 x'_k 的位置。给定一个搜索空间 $w \in \Omega$ ，中心为 w_0 ，边界为 w_{\min} 和 w_{\max} ，定义

$$\alpha_k(\Omega) := 0.5 \|\omega_{\min} t_k - \omega_{\max} t_k\|_2.$$

所有可能的旋转轴承矢量 \mathbf{f}'_k 将位于一个圆锥体中，如图所示：

$$\mathcal{V}_k(\Omega) := \{\mathbf{f} \in \mathbb{R}^3 \mid \angle(\exp(\omega_0^\wedge t_k) \mathbf{f}_k, \mathbf{f}) \leq \alpha_k(\Omega)\}.$$

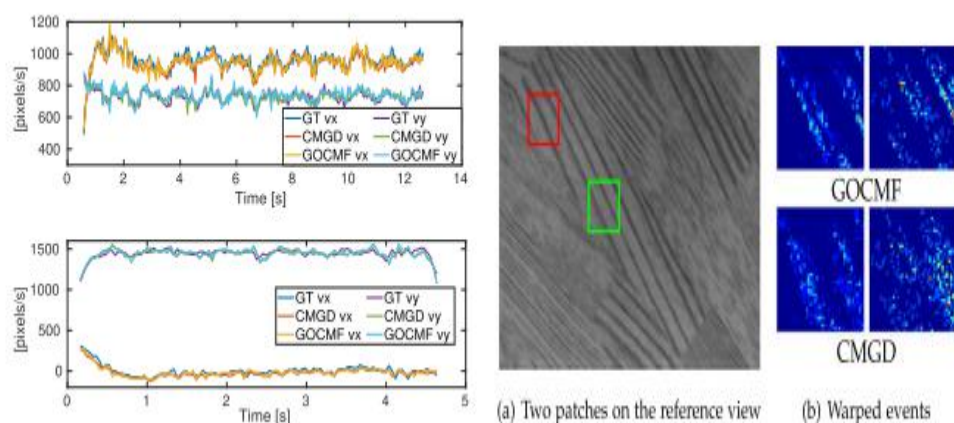


实验对比

1、光流估计

我们使用安装在自主地面车辆 (AGV) 上的朝下事件相机在我们自己收集的两个序列“圆”和“线”上测试我们的全局最优光流估计算法；

将 GOCMF 与 CMGD (使用 Matlab 的 `fmincon` 函数的局部优化方法) 和地面实况进行比较。



结果定性分析：

- ① 可以看出两种方法估计结果与实况非常吻合。
- ② 本文方法产生的 IWE 更加锐利。

TABLE 2
Runtimes and Average Endpoint Errors (AEE) for
GOCMF and CMGD

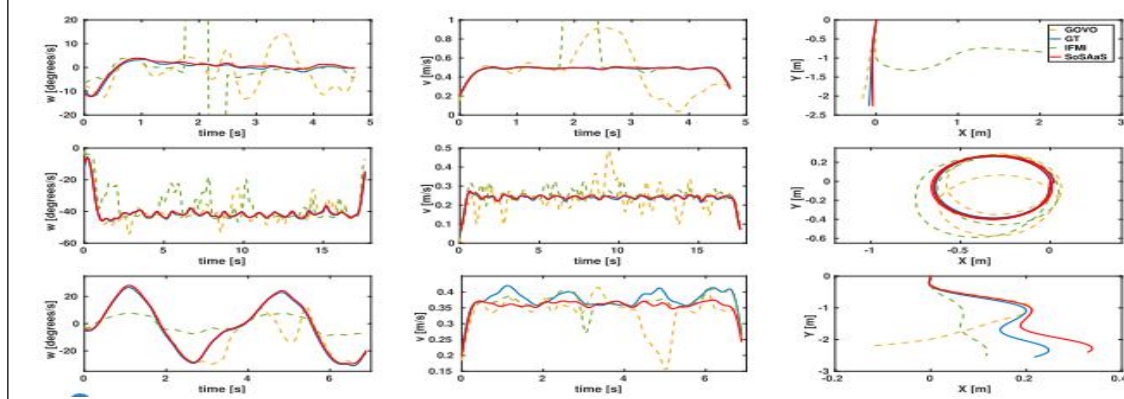
Method	Circle		Line	
	AEE	time [s]	AEE	time [s]
CMGD	1.22	12.12	1.12	9.59
GOCMF	1.15	34.23	0.98	28.73

结果定量分析：

- ① 主要评估了 GOCMF 和 CMGD 的运行时间和平均端点错误 (AEE)；可以看出本文方法更加精确，但运行时间更长。

2、向下事件相机的运动估计

我们在木纹泡沫上记录了几个运动序列，该泡沫具有高度自相似的纹理，并对可靠地提取和匹配特征提出了挑战；本文方法与 GOVO 和 IFMI 作比较（是基于帧的算法，专门为无特征条件下的平面 AGV 运动估计而设计）；



结果定性分析:

前两列是 w 和 v 随时间变化的误差, 第 3 列是鸟瞰图

①可以看出 IFMI 和 GOVO 偶尔都会丢失跟踪 (尤其是线性运动), 本文的 L_{SoSAaS} 的全局最优基于事件的方法更优;

TABLE 3
RMS errors for Event-Based and Frame-Based Methods

Method	Line		Circle		Curve	
	w [°/s]	v [m/s]	w [°/s]	v [m/s]	w [°/s]	v [m/s]
GOCMF	0.517	0.008	0.529	0.004	0.554	0.018
IFMI	145.37	1.059	8.109	0.024	12.804	0.019
GOVO	6.970	0.240	4.550	0.064	9.865	0.059

结果定量分析:

①角速度和线速度的 RMS 误差, 可以看出 GOCMF 的均方误差非常小, 精确度非常高;

3、旋转运动估计

我们继续对所提出的算法 GOCMF 和替代全局最优算法 CMBNB、局部优化器 CMGD 进行比较。我们使用中公开的序列海报、方框和动态, 这些是使用 Davis240C 在静态室内场景上的旋转运动下记录的。

使用两个误差指标评估算法, 其中 w_{gt} 和 w_{est} 地面实况角速度和估计角速度

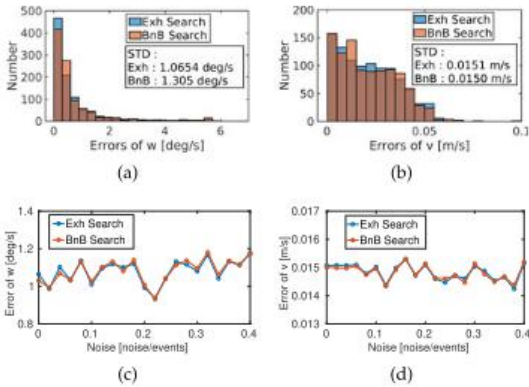
$$\epsilon = \|\omega_{gt} - \omega_{est}\|_2,$$
$$\phi = |||\omega_{gt}\|_2 - \|\omega_{est}\|_2|.$$

Method	dynamic					boxes					poster				
	$\mu(\phi)$	$\delta(\phi)$	$\mu(\epsilon)$	$\delta(\epsilon)$	time	$\mu(\phi)$	$\delta(\phi)$	$\mu(\epsilon)$	$\delta(\epsilon)$	time	$\mu(\phi)$	$\delta(\phi)$	$\mu(\epsilon)$	$\delta(\epsilon)$	time
CMGD	161.6	127.9	168.7	124.1	6.96	61.75	103.6	71.82	101.0	9.08	43.64	74.29	59.29	79.29	16.63
CMBNB	9.88	6.94	17.02	8.93	76.46	19.41	13.34	30.21	15.49	92.48	22.05	23.18	32.94	23.87	221.0
GOCMF	9.75	6.66	17.05	8.58	22.88	20.19	16.19	31.27	21.10	30.08	21.98	23.02	32.39	23.44	88.48

结果定量分析:

- ①全局最优方法比 CMGD 具有更低的错误。
- ②此外, 我们的算法在动态数据集和海报数据集上的表现略好于 CMBNB, 而 CMBNB 在盒子上的表现略好。

4、精确性和鲁棒性分析



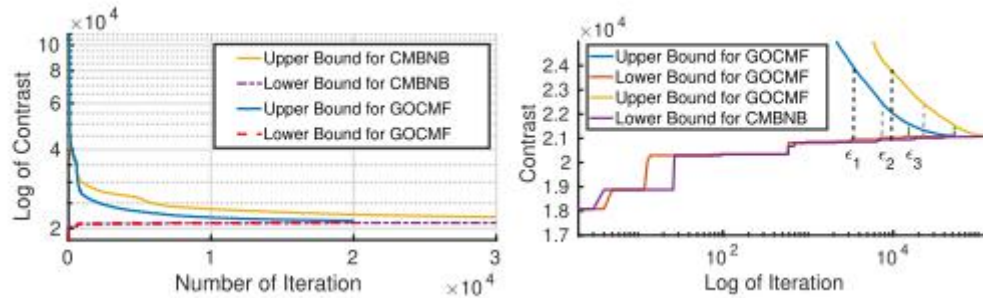
结果定量分析:

①a 和 b 表示出了在无噪声情况下穷举搜索和 BnB 的标准差的误差分布; 表明 BnB 运行良好并且可持续地返回非常接近穷举搜索找到的最优结果的结果。

②为了分析鲁棒性, 我们将椒盐噪声随机添加到事件流中, 噪声与事件 (N/E) 比率在 0-0.4, c 和 d 显示了在 1000 次实验中再次平均的每个噪声水平的误差。可以看出, 误差非常相似, 并且或多或少地与添加的噪声量无关。后一个结果强调了我们方法的高度稳健性。

5、GOCMF 和 CMBNB 的约束收敛性

即证明导出的边界随着分支尺寸的减小而收敛

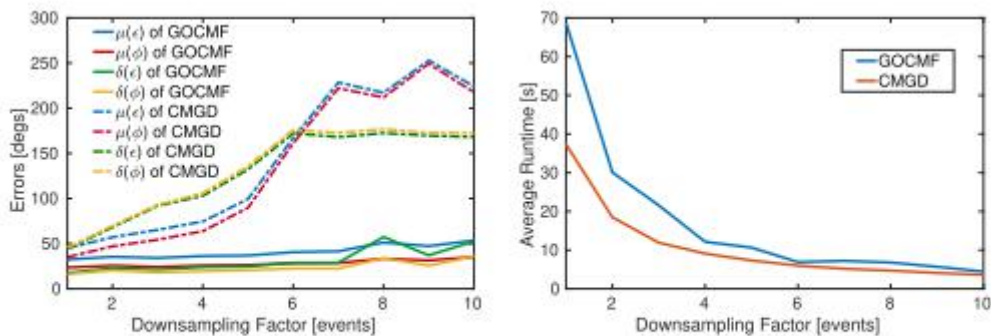


结果分析:

①明显看出 GOCMF 比 CMBNB 收敛得更快, CMBNB 至少在 30000 次迭代时终止, 而 GOCMF 在大约 20000 次迭代时终止, 如左图所示。性能差异是由于 GCMF 的边界更严格造成的。为了指示下界的迭代, 我们展示了带有迭代日志的右图。表示所选的收敛标准--上限和下限之间的差距越小, 迭代次数越多, 越准确。

6、下采样机制来加速 GOCMF 算法

对比度最大化评估 IWE 的锐度, 该属性对于事件流的下采样具有一定的鲁棒性。我们评估了具有不同下采样因子的序列框的最后 15 秒内局部优化(CMGD)和 GOCMF 的准确性。m 的下采样因子仅意味着在按时间顺序排列的事件序列中, 仅保留第 m 个事件。在此实验中, 我们测试范围从 1 到 10 的下采样因子



(a) errors with decreasing sample rate (b) average runtime with decreasing sample rate

结果分析:

①a 说明了随着下采样因子的增加, 两者的误差都随着下采样因子的增加而增加。但 GOCMF 仍然比 CMGD 更加稳健。

②b 进一步表明了 GOCMF 和 CMGD 的平均运行时间。随着采样率的降低, 运行时间呈指数下降。

7、GOCMF 在六种目标函数下的准确性

使用本文六个对比函数在直线、圆形和任意弯曲的轨迹测试算法, 比较 RMS 误差

RMS Errors for Different Datasets and Methods						
Method	Line	Line	Circle	Circle	Curve	Curve
	w [°/s]	v [m/s]	w [°/s]	v [m/s]	w [°/s]	v [m/s]
SoE	2.408	0.015	2.212	0.025	3.628	0.026
SoEaS	2.405	0.015	2.017	0.024	3.628	0.026
SoS	0.512	0.008	1.088	0.008	3.009	0.021
SoSA	1.961	0.028	4.249	0.073	9.290	0.072
SoSAaS	0.517	0.008	0.529	0.004	0.554	0.018
Var	0.512	0.008	1.088	0.008	3.009	0.020

结果分析：

① L_{SoS} 和 L_{Var} 表现良好， L_{SoSAaS} 表现最好。

实验结论	<p>我们引入了一种新颖的全局最优解决方案来实现单应校正事件流的对比度最大化。</p> <p>① 成功地将其应用于三种不同的场景，包括光流、纯旋转估计和朝下事件相机的非完整运动估计。</p> <p>② 该 GCOMF 模型精确性和鲁棒性都很强，且相比于现在最新的 CMBNB 的收敛速度也更快。</p> <p>③ 本算法可以通过下采样来提升算法的速度。</p>
不足	<p>① 增加了全局最优 BnB 算法的计算复杂性，较高的计算成本，占用的计算时间较长。</p> <p>② 本文没有针对低光照、遮挡问题的实验</p>
收获启示	<p>① 本文采用了全局最优解方法，提出了一种基于分支定界(BnB)优化范式(ϵ 最优解)的高效、全局最优对比度最大化框架(GOCMF)，解决了先前 CM 存在的局部最优解，过拟合的问题。</p> <p>② 本文采用下采样来减少计算复杂度，但对于大数据量可能会存在数据信息丢失等问题。</p>