

文献阅读笔记			
题目	Single Image Optical Flow Estimation with an Event Camera (基于事件相机的单图像光流估计)		
作者	Liyuan Pan	文献来源	2020 CVPR
研究问题	用事件摄像机 (DAVIS) 的单幅图像及其事件数据的进行光流估计		
研究价值	<p>传统方法: 首先从事件重建图像, 然后直接从重建的图像计算光流。但是这种方法忽略了流和事件之间的内在联系。</p> <p>本文价值: 本文利用 DAVIS 输出 (事件和强度图像) 来估计光流, 从单个图像和事件估计的流更稳健, 该模型对于处理复杂场景中的模糊图像具有很好的泛化能力。</p> <p>我的理解: 传统方法需要对事件流进行操作输出为图像, 用重构的图像来估计光流, 而忽略了 DAVIS 在输出高分辨率的事件的同时还输出低帧强度图像。本文是不需要将事件流重构成图像, 而是同时对事件流和强度图像 (可能模糊) 进行处理, 来实现光流估计。</p>		
想法动机	<p>主要: 引入基于事件的绝对强度亮度恒定约束来编码光流和事件数据之间的关系, 在目标函数中使用模糊形成的模型来对模糊图像进行光流估计, 使用主对偶算法将流量估计 u 和图像去模糊 L 归结为一个目标函数的交替优化问题。</p> <p>1、如何将事件与光流联系起来-----亮度恒定约束 ϕ_{eve}</p> <p>2、模糊图像与光流联系起来-----将 EDI 模型和最新的光流估计方法结合起来 ϕ_{blur}</p> <p>3、平滑-----平滑项估计光流 ϕ_{flow} 和潜像 ϕ_{im}</p> <p>我的理解: 直接在流量估计框架中对事件进行建模, 先设定亮度恒定, 再借助事件和模糊图像形成模型, 来联合估计流量 u 和潜像 L。且模糊图像中的伪影为流量估计提供了有用的信息。光流法基本假设: 一是亮度恒定, 二是运动为小运动。</p> <p>补充:</p> <p>主对偶算法: 是一类优化算法, 用于解决凸优化问题。这类算法的基本思想是同时优化原始问题和对偶问题。</p> <p>主对偶算法的迭代步骤:</p> <p>① 更新原始变量 (x): 利用对偶变量更新原始变量, 通过对原始问题进行梯度下降或其他优化方法。</p> <p>② 更新对偶变量 (y): 利用原始变量更新对偶变量, 通过对对偶问题进行梯度上升或其他优化方法。</p> <p>这两个步骤是交替进行的, 直到满足收敛准则为止。</p>		

具体方法

背景知识:

定义 $u = (u, v)$ 为光流场, 并且 $u(x) = (u_x, v_x)^T$ 为其在像素 x 处的值。从参考时间 f 到 t , 亮度恒定度可写为:

$$L(x, f) = L(x + u(x), t)$$

设像素 $x = (x, y)^T$ 在时间 f 处的强度由 $L(x, f)$ 表示。由于方程(1)未定, 引入正则化项来求解光流。则该问题的变分公式为:

$$\min_u \int_{\Omega} \|\nabla u(x)\|^2 dx + \int_{\Omega} (L(x, f) - L(x + u(x), t))^2 dx$$

其中 Ω 表示图像域, 第一项惩罚 u 的高变化以获得平滑的光流场, 第二项强制执行亮度恒定约束 (BCC), 定义 $\nabla u(x)$ 为:

$$\nabla u(x) = \left(\frac{\partial u(x)}{\partial x}, \frac{\partial u(x)}{\partial y}, \frac{\partial v(x)}{\partial x}, \frac{\partial v(x)}{\partial y} \right)^T$$

可将其简写为 $\nabla u(x) = (u(x)^{(x)}, u(x)^{(y)}, v(x)^{(x)}, v(x)^{(y)})^T$ 。

通过事件和模糊图像形成模型强制亮度恒定性来联合估计流量 u 和潜像 L 。我们的能量最小化模型表述为:

$$\min_{L, u} \mu_1 \phi_{eve}(L, u) + \mu_2 \phi_{blur}(L, u) + \phi_{flow}(\nabla u) + \phi_{im}(\nabla L) \quad (1)$$

其中 μ_1 和 μ_2 是权重参数, ϕ_{eve} 通过事件强制 BCC, ϕ_{blur} 强制模糊图像形成过程, ϕ_{flow} 和 ϕ_{im} 强制估计流和潜像的平滑度。

1、事件数据的亮度恒定性 ϕ_{eve}

当强度的变化超过阈值 c 时, 会触发事件。设 t 是当前时间戳, t_{ref} 是前一个事件的时间戳。当事件被触发时, 该像素处的 t_{ref} 和 $L(x, t_{ref})$ 被更新为新的时间戳和新的强度级别。遵循 EDI 模型, 我们将相邻图像表示为:

$$L(x, t) = L(x, f) \exp(cE(x, t))$$

其中 $E(x, t)$ 是给定像素 x 处在时间 f 和 t 间事件的积分, 我们将 $E(t)$ 称为事件框架。

假设 $\Delta t = t - f$ 之间的运动很小。我们对 $L(x, f) = L(x + u(x), t)$ 的右侧采用一阶泰勒展开式。具体操作如下:

$$\begin{aligned}
& \text{假设:} \\
& L(x, f) = L(x + u(x), t) \quad ① \\
& E \cdot D I = L(x, t) = L(x, f) \exp(c E(x, t)) \quad ② \\
& \Delta t = t - f \\
& \text{泰勒展开:} \\
& L(x + u(x), \Delta t + f) \approx L(x, f) + \left(u_x \frac{\partial}{\partial x} + v_x \frac{\partial}{\partial y} \right) L(x, f) + \frac{\partial L(x, f)}{\partial t} \Delta t \\
& \left(\because L(x, t) = L(x, f) + \frac{(t-f)}{\Delta t} \frac{\partial L(x, f)}{\partial t} \right) \\
& \therefore = u_x L(x, f)^{(x)} + v_x L(x, f)^{(y)} + L(x, t) \\
& \therefore L(x, f) \approx u_x L(x, f)^{(x)} + v_x L(x, f)^{(y)} + \frac{L(x, t)}{\Delta t} \quad ③ \\
& \therefore L(x, f) \approx \underbrace{u_x L(x, f)^{(x)} + v_x L(x, f)^{(y)}}_{\nabla L(x, f) = (L(x, f)^{(x)}, L(x, f)^{(y)})^T} + L(x, f) \exp(c E(x, t)) \\
& \therefore L(x, f) \approx [\underbrace{u_x, v_x}_{\nabla L(x, f)}]^T \nabla L(x, f) + L(x, f) \exp(c E(x, t))
\end{aligned}$$

最终，我们将基于事件的光度恒定性约束写为：

$$\phi_{eve}(L, u) = \sum_{x \in \Omega} \| L(x, f) (\exp(c E(x, t)) - 1) + [u_x, v_x]^T \nabla L(x, f) \|_1 \quad (2)$$

2、模糊图像形成约束 ϕ_{blur}

除了事件流之外，DAVIS 还提供强度图像。由于相机和物体之间的相对运动，图像可能会出现运动模糊。模糊图像形成的一般模型由下式给出：

$$B = k \otimes L(f)$$

其中 B 是模糊图像， \otimes 是卷积算子，k 表示模糊核。对于动态场景，原则上为每个像素定义空间变化模糊内核，表达式为：

$$B(x) = k(x) \otimes L(x)$$

两个矩阵的卷积定义为，

$$B(x) = \sum_{y \in \Omega} k(y) L(x - y) = \sum_{y \in \Omega} k_{u'(x)}(y) L(x - y)$$

其中 $k_{u'(x)}$ 是每个像素的核映射。我们用下标 $u'(x)$ 表示像素 x 的 k 索引， $k_{u'(x)}(y)$ 表示为：

$$k_{u'(x)}(y) = \begin{cases} \frac{1}{|u'(x)|}, & \text{if } y = \alpha u'(x), |\alpha| \leq \frac{1}{2} \\ 0, & \text{otherwise,} \end{cases}$$

其中 $u'(x) = \lambda u(x)$ 表示曝光时间 T 期间的光流，且 $\lambda = T / \Delta t$ （短时间内光流速度恒定）。

此外，核的每个元素都是非负的，并且其总和等于一。请注意，方程中定义的内核使我们能够处理长曝光时间 T 的模糊图像，以及短曝光时间的清晰图像。当 T 很小时， θ 小到足以产生作为模糊内核的狄拉克 δ 函数。模糊图像形成约束表示为

$$\phi_{blur}(L, u) = \sum_{x, y \in \Omega} \| k_{u'(x)}(y) L(x - y) - B(x) \|^2 \quad (3)$$

可以在统一的框架内处理模糊和清晰的图像。

3、平滑项 ϕ_{flow} 和 ϕ_{im}

一般来说，传统的流量估计模型假设流量矢量平滑变化并且在图像边缘具有稀疏的不连续性。平滑项旨在通过最小化相邻像素之间的差异来规范流量和图像。对于任意像素 x ，向量 $w(x) = (w_x^x, w_x^y)$ ，定义：

$$w(x)\nabla u(x) = (w_x^x u_x^{(x)}, w_x^y u_x^{(y)}, w_x^x v_x^{(x)}, w_x^y v_x^{(y)})^T$$

将所有像素放在一起，定义 $w\nabla u$ ，则光流成本为：

$$\phi_{flow}(\nabla u) = \|w\nabla u\|_{1,2} = \sum_{x \in \Omega} \|w(x)\nabla u(x)\| \quad (4)$$

这是混合 1-2 范数（2 范数之和）。我们选择权重 w ，其中：

$$w^x = \mu_3 \exp(-(\hat{L}^{(x)} / \mu_4)^2)$$

其中，常数 μ_3 和 μ_4 是权重参数， \hat{L} 是我们优化框架的输入图像。此外，我们将图像平滑项定义为

$$\phi_{im}(\nabla L) = \sum_{x \in \Omega} \|\nabla L(x)\|_1 \quad (5)$$

4、最优化算法

等式(1)相对于 u 和 L 是非凸的。因此，我们一次对一个变量进行优化，并以交替的方式优化所有参数。在这里，我们使用主对偶算法来实现最佳收敛。

- ① 固定潜像 L ，并通过优化方程计算光流 u 。
- ② 固定光流 u ，并通过优化方程计算潜像 L 。

(1) 光流估计

我们固定图像，即 $L = \hat{L}$ ，则方程 (1) 简化为

$$\min_u \underbrace{\mu_1 \phi_{eve}(u) + \mu_2 \phi_{blur}(u)}_{G(u)} + \underbrace{\phi_{flow}(\nabla u)}_{F(Ku)}$$

其中 $\phi_{eve}(u)$ 和 $\phi_{flow}(\nabla u)$ 是凸的，而 $\phi_{blur}(u)$ 是非凸的。我们将方程分为 G 和 F ，其中 $Ku = w\nabla u$ 是线性函数， $F(Ku) = \|Ku\|_{1,2} = \phi_{flow}(\nabla u)$ 。设 $u \in X = \mathbb{R}^{2N}$ ，且 $\nabla u \in Y = \mathbb{R}^{4N}$ ，因此 $G: X \rightarrow \mathbb{R}$ ，且 $F: Y \rightarrow \mathbb{R}$ ，其中 N 是像素数。将 u ， ∇u 视为向量。原对偶公式的基础是用双 Fenchel 对偶 F^{**} 替换方程中的 F 得到，因此变为 $\min(G(u) + F^{**}(Ku))$ ，

$$\min_{u \in X} \left(G(u) + \max_{p \in Y} \langle Ku, p \rangle_X - F^*(p) \right)$$

回想一下，函数 F 的 Fenchel 对偶（凸共轭） F^* 定义为

$$F^*(q) = \sup_{p \in Y} (\langle p, q \rangle - F(p))$$

如果 F 是凸函数（范数是凸函数），则 $F = F^{**}$ 。主对偶算法由从初始估计 u^0, p^0 和 $\bar{u}^0 = u^0$

开始的迭代组成：

$$\begin{aligned}\mathbf{p}^{n+1} &= \mathcal{P}_{F^*}(\mathbf{p}^n + \sigma K \bar{\mathbf{u}}^n) \\ \mathbf{u}^{n+1} &= \mathcal{P}_G(\mathbf{u}^n - \tau K^* \mathbf{p}^{n+1}) \\ \bar{\mathbf{u}}^{n+1} &= \mathbf{u}^{n+1} + \theta(\mathbf{u}^{n+1} - \mathbf{u}^n)\end{aligned}$$

这里 σ 和 τ 是权重参数， $\mathcal{P}(\cdot)$ 是近端算子。

$$\mathcal{P}_g(x) = \arg \min_y (2g(y) + \|y - x\|^2)$$

超参数 θ 是一个控制“外推”程度的数字。使用 $\theta = 1$ 。

更新 \mathbf{p}

众所周知，范数的芬切耳对偶是对偶范数中单位球的指示函数。在这种情况下， $F^*(\cdot)$ 是一个 1 和 2 混合范数，它的对偶是一个 $\infty, 2$ 混合范数。因此，指示函数是 N 个欧几里德 2-球的乘积 B^N 。更确切地说

$$F^*(\mathbf{p}) = \begin{cases} 0, & \text{if } \|\mathbf{p}_x\| \leq 1 \text{ for all } x \\ +\infty, & \text{otherwise} \end{cases}$$

近端算子 \mathcal{P}_{F^*} 由下式给出

$$\begin{aligned}F^*(\bar{\mathbf{p}}) &= \arg \min_{\mathbf{p} \in Y} (2F^*(\mathbf{p}) + \|\bar{\mathbf{p}} - \mathbf{p}\|^2) \\ &= \arg \min_{\mathbf{p} \in B^N} \|\bar{\mathbf{p}} - \mathbf{p}\|^2.\end{aligned}$$

换句话说，每个 \bar{p}_x 被投影到单位球中最近的点，由 $\bar{p}_x / (\max(1, \|\bar{p}_x\|))$ 给出。

更新 \mathbf{u}

方程的更新方程是：

$$\begin{aligned}\bar{\mathbf{u}} &= \mathbf{u}^n - \tau K^* \mathbf{p}^{n+1} \\ \mathbf{u}^{n+1} &= \mathcal{P}_{\tau G}(\bar{\mathbf{u}}) = \arg \min_{\mathbf{u}} (2\tau G(\mathbf{u}) + \|\mathbf{u} - \bar{\mathbf{u}}\|^2)\end{aligned}$$

通过求导来最小化得到 $\mathbf{u} = \bar{\mathbf{u}} - \tau \nabla G(\mathbf{u})$ 。我们做出简化假设， G 局部逼近一阶，因此

$\nabla G(\mathbf{u}) = \nabla G(\mathbf{u}^n)$ ，得到迭代步骤

$$\mathbf{u}^{n+1} = \mathbf{u}^n - \tau (\nabla G(\mathbf{u}^n) + K^* \mathbf{p}^{n+1})$$

这只是方程的梯度下降，固定 $\mathbf{p} = \mathbf{p}^{n+1}$ 。

(2) 去模糊

我们固定光流，即 $\mathbf{u} = \hat{\mathbf{u}}$ ，并且方程 (1) 简化为：

$$\min_{\mathbf{L}} \underbrace{\phi_{\text{im}}(\nabla \mathbf{L})}_{F_1(\nabla \mathbf{L})} + \underbrace{\mu_1 \phi_{\text{eve}}(\mathbf{L})}_{F_2(K\mathbf{L})} + \underbrace{\mu_2 \phi_{\text{blur}}(\mathbf{L})}_{G(\mathbf{L})}$$

凸共轭 F^* 定义为：

$$F^*(\mathbf{p}, \mathbf{q}) = F_1^*(\mathbf{p}) + F_2^*(\mathbf{q})$$

主对偶更新过程表示如下：

$$\begin{aligned}\mathbf{p}^{n+1} &= \frac{\mathbf{p}^n + \gamma \nabla \bar{\mathbf{L}}^n}{\max(1, \text{abs}(\mathbf{p}^n + \gamma \nabla \bar{\mathbf{L}}^n))}, \\ \mathbf{q}^{n+1} &= \frac{\mathbf{q}^n + \gamma(\theta_2 \bar{\mathbf{L}}^n + [u, v]^T \nabla \bar{\mathbf{L}}^n)}{\max(1, \text{abs}(\mathbf{q}^n + \gamma(\theta_2 \bar{\mathbf{L}}^n + [u, v]^T \nabla \bar{\mathbf{L}}^n)))}\end{aligned}$$

其中 η 、 γ 是权重因子， $\theta_2 = \exp(cE(t)) - 1$ 。

$$\mathbf{L}^{n+1} = \mathcal{P}_{\eta G}(\bar{\mathbf{L}}) = \arg \min_{\mathbf{L}} (2\eta G(\mathbf{L}) + \|\mathbf{L} - \bar{\mathbf{L}}\|^2)$$

其中 $\bar{\mathbf{L}} = \mathbf{L}^n - \eta(\nabla^* \mathbf{p}^{n+1} + K^* \mathbf{q}^{n+1})$ 。

Algorithm 1: Primal-Dual Minimization - Flow

Initialization: Choose $\tau, \sigma > 0, n = 0$, and set $\bar{\mathbf{u}}^0 = \mathbf{u}^0$.

Iterations : Update $\mathbf{u}^n, \mathbf{p}^n, \bar{\mathbf{u}}^n$ as follows

```

1 while  $n < 20$  do
2   Dual ascent in  $\mathbf{p}$ 
3    $\bar{\mathbf{p}} = \mathbf{p}^n + \sigma K \bar{\mathbf{u}}^n, \mathbf{p}_x^{n+1} = \bar{\mathbf{p}}_x / \max(1, \|\bar{\mathbf{p}}_x\|) \forall x$ 
4   Primal descent in  $\mathbf{u}$ 
5    $\mathbf{u}^{n+1} = \mathbf{u}^n - \tau(G(\mathbf{u}^n) + K^* \mathbf{p}^{n+1})$ 
6   Extrapolation step
7    $\bar{\mathbf{u}}^{n+1} = \mathbf{u}^{n+1} + (\mathbf{u}^{n+1} - \mathbf{u}^n)$ 
8    $n = n + 1$ 
9 end

```

Algorithm 2: Primal-Dual Minimization - Deblurring

Initialization: Choose $\gamma, \eta > 0, n = 0$, and set $\bar{\mathbf{L}}^0 = \mathbf{L}^0$.

Iterations : Update $\mathbf{L}^n, \mathbf{p}^n, \mathbf{q}^n$ as follows

```

1 while  $n < 5$  do
2   Dual ascent in  $\mathbf{p}, \mathbf{q}$ 
3    $\bar{\mathbf{p}} = \mathbf{p}^n + \gamma \nabla \bar{\mathbf{L}}^n, \bar{\mathbf{q}} = \mathbf{q}^n + \gamma(\theta_2 \bar{\mathbf{L}}^n + [u, v]^T \nabla \bar{\mathbf{L}}^n)$ 
4    $\mathbf{p}_x^{n+1} = \bar{\mathbf{p}}_x / \max(1, \text{abs}(\bar{\mathbf{p}}_x)) \forall x$ 
5    $\mathbf{q}_x^{n+1} = \bar{\mathbf{q}}_x / \max(1, \text{abs}(\bar{\mathbf{q}}_x)) \forall x$ 
6   Primal descent in  $\mathbf{L}$ 
7    $\bar{\mathbf{L}} = \mathbf{L}^n - \eta(\nabla^* \mathbf{p}^{n+1} + K^* \mathbf{q}^{n+1}), \mathbf{L}^{n+1} = \mathcal{P}_{\eta G}(\bar{\mathbf{L}})$ 
8   Extrapolation step
9    $\bar{\mathbf{L}}^{n+1} = \mathbf{L}^{n+1} + (\mathbf{L}^{n+1} - \mathbf{L}^n)$ 
10   $n = n + 1$ 
11 end

```

实验对比

数据集：

①真实数据集：多车辆立体事件相机数据集（MVSEC）、事件相机数据集（ECD）和模糊事件数据集（BED）。

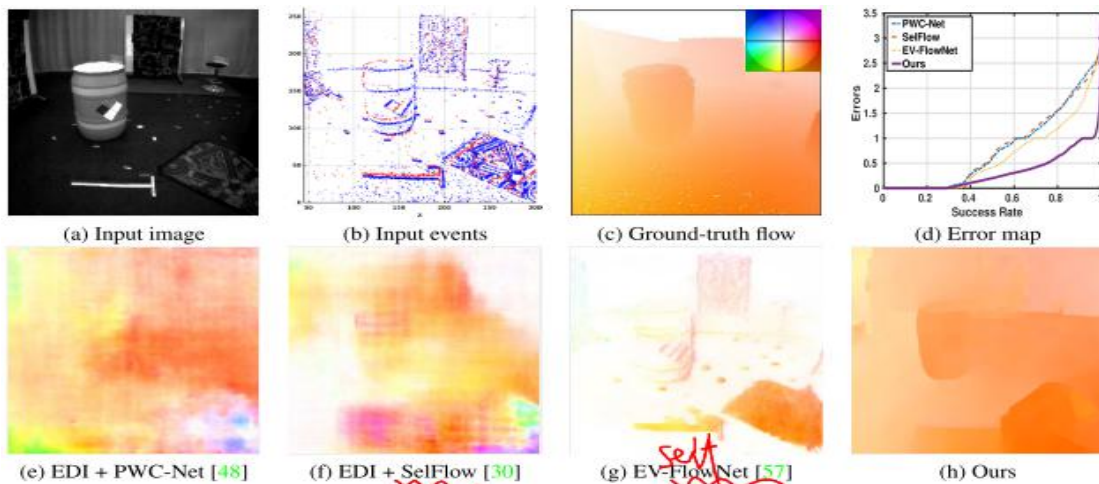
②合成数据集：为了对光流进行定量比较，我们基于 Sintel 构建了一个图像尺寸为 1024×436 的合成数据集，但它不适合去模糊的评价；为了提供定量的去模糊比较，我们基于真实的 GoPro 视频数据集生成另一个包含事件和运动模糊的合成数据集，其中图像大小为 1280×720 。它具有地面实况潜在图像和相关的运动模糊图像。我们还使用 PWC-Net 从清晰图像中估计流量，作为流量评估的基本事实。

评估指标：使用误差度量，均方误差（MSE）、平均端点误差（AEE）和流量误差度量（FE）。我们采用 PSNR 来评估去模糊图像。误差图显示了测量的端点误差与地面实况流相比的分布，成功率定义为误差低于阈值的结果的百分比。

1、实验——评估光流

在真实数据集 MVSEC 和模拟数据集上评估光流

MVSEC dataset [57]							
Input	GT images		EDI images and events		Events		Ours
	SelFlow [30]	PWC-Net [48]	SelFlow [30]	PWC-Net [48]	EV-FlowNet [57]	Zhu et al. [59]	
AEE	0.5365	0.4392	1.4232	1.3677	1.3112	0.6975	0.9296
MSE	0.3708	0.1989	1.7882	1.6135	1.3501	-	0.8700
FE (%)	0.5163	0.0938	2.5079	2.4927	1.1038	1.7500	0.4768
Sintel dataset [10]							
AEE	0.1191	0.1713	1.3895	1.5138	2.9714	-	1.0735
MSE	0.3645	0.5979	6.2693	7.6105	21.4982	-	3.2342
FE (%)	0.8155	1.1922	22.6290	21.9625	49.0136	-	14.9061



结果定量分析：

①与 MVSEC 数据集上仅基于事件的方法、“EDI + SelFlow”和“EDI + PWC-Net”相比，我们在流量估计方面取得了有竞争力的结果，与 Sintel 数据集相比，我们的方法也更准确。

结果定性分析：

①误差图 d 显示了与真实流相比估计的端点误差的分布，可以看出我们的方法误差相对较小；

②与基于重建图像“EDI + SelFlow”和“EDI + PWC-Net”、最新的基于事件的方法进行对比，可以明显看出我们的方法估计的光流更加接近真实光流。

2、实验——评估去模糊/消融实验/效率

- (1) 在 GoPro 数据集上的去模糊比较，对 GoPro 数据集的定量分析；
- (2) 证明我们的优化方法的效率，使用“EDI+ PWC-Net”的输出作为我们方法的输入；
- (3) 评估了 ϕ_{eve} 和 ϕ_{blur} 的影响。

Input	EDI images and events		Events	Image and events		
	SelfFlow [30]	PWC-Net [48]	EV-FlowNet [57]	EDI + PWC-Net + Our optimization	Our initialization	Our results
AEE	2.0557	1.5806	2.0337	0.9796	3.7868	0.8641
MSE	5.7199	4.8951	10.5480	2.5952	8.3929	2.1536
FE(%)	0.1722	0.1049	0.2839	0.0895	0.1218	0.0632
PSNR	-	-	-	31.5595	29.3789	31.9234


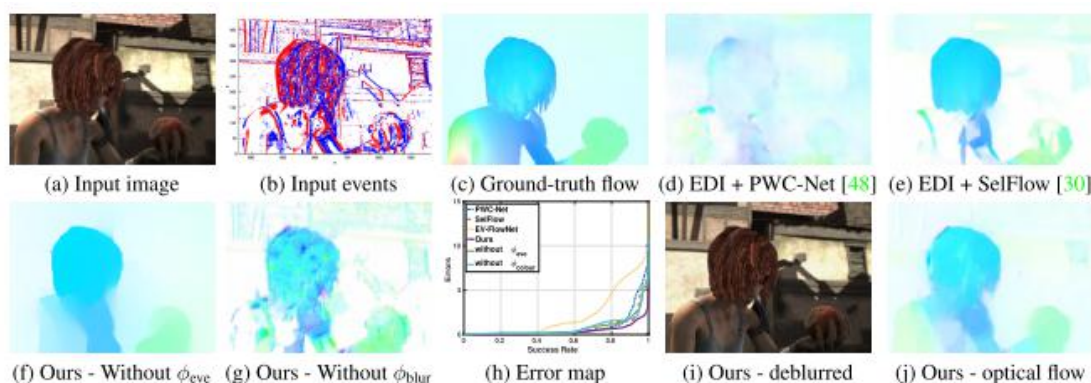


Table 2. Ablation Study based on Sintel Dataset [10].

	without ϕ_{eve}	without ϕ_{blur}
AEE	2.3941	2.2594
MSE	5.3506	9.5267
FE (%)	18.0525	45.4516

结果分析:

- ① 可以看出我们的方法在去模糊方面优于所有基线方法。
- ② 使用“EDI+ PWC-Net”的输出作为我们方法的输入，可以看出我们的方法效率更高。
- ③ 消融实验可以看出，本文方法中的每一个约束都对有影响，其中 ϕ_{blur} 在 Sintel 数据集上表现的更重要。

实验结论

在本文中，我们基于单个图像（可能模糊）和 DAVIS 事件联合估计光流和清晰强度图像。

1、事件是可以加强流量估计的高效数据，包含单个图像有助于实现比仅基于事件的方法更好的流量估计，特别是在没有事件的区域中；

2、本文方法在不同数据集上的表现，都优于目前所有基线方法，可以看出我们模型的泛化能力、有效性和准确性。

不足	<p>1、虽然我们的方法可以处理高动态情况，但我们在处理低纹理场景方面仍然存在困难，在图像的边缘或角落，事件数据可能不足以提供准确的光流信息，这可能会导致边界条件处理不当。</p> <p>2、对噪声的敏感性，尽管主对偶方法在优化问题中表现出了一定的鲁棒性，但在实际应用中，如何处理和抑制噪声仍然是一个挑战，特别是来自事件数据的噪声。</p> <p>3、在数据不充分或噪声水平较高的情况下，主对偶优化方法可能存在收敛性问题。</p>
收获启示	<p>1、本文是结合了事件流和强度图像，这种融合能够充分利用各种传感器的优势，弥补单一传感器的不足，得到更好的性能。</p> <p>2、未来可以将主对偶方法与神经网络结合，允许端到端的训练，即从输入图像直接到光流估计的输出。</p>